

Relatório Final de Análise de Dados:

Base de Varejo

Autoria: Claudia Pedroso Ferreira (claudinha08@gmail.com)

Contexto: Mini Projeto - Manipulação de Dados com Python e SQL

Dataset: Base de Varejo (Kaggle)

1. Sumário Executivo

Este relatório técnico consolida todas as etapas metodológicas de importação, higienização de dados textuais e numéricos, tratamento de valores faltantes e duplicatas, e análise exploratória e estatística realizadas sobre a base de dados de varejo. O principal propósito do pipeline desenvolvido em Python foi estruturar uma base confiável e consistente para fundamentar a tomada de decisão estratégica.

2. Metodologia e Pipeline de Dados (Sprints)

O projeto foi estruturado segundo um fluxo analítico sequencial dividido em quatro sprints principais:

Sprint 1: Importação e Diagnóstico Estrutural

- **Carga dos Dados:** Leitura e carregamento do arquivo tabular Varejo.csv utilizando a biblioteca pandas.
- **Diagnóstico Preliminar:** Avaliação inicial de volumetria de dados, contagem total de registros (linhas), número de colunas e inspeção dos tipos primitivos (dtypes).

Sprint 2: Diagnóstico e Transformação (Expressões Regulares)

- **Mapeamento de Inconsistências:** Verificação e contagem de dados faltantes (`isnull().sum()`) e registros duplicados.
- **Higienização de Strings:** Aplicação de rotinas de limpeza com expressões regulares (`re.sub`) para remoção de pontuações indesejadas, caracteres especiais e espaços excedentes.
- **Padronização Numérica:** Isolamento de caracteres numéricos em campos cadastrais/identificadores para garantir a integridade dos identificadores.

Sprint 3: Limpeza de Nulos, Duplicatas e Conversão de Tipos

- **Deduplicação:** Identificação de linhas redundantes através de drop_duplicates.
- **Tratamento Temporal:** Conversão e formatação de colunas de datas para o formato datetime.
- **Estratégia de Imputação de Nulos:**
 - *Variáveis Numéricas Contínuas e Discretas:* Imputação pela mediana amostral, conferindo robustez contra a influência de outliers.


Sprint 4: Análise Estatística Descritiva e Agrupamentos

- Cálculo de parâmetros de posição, dispersão e distribuição focados na coluna de número de dependentes (CL_FHL) e cruzamentos demográficos (como distribuição de gênero).

3. Análise Estatística Descritiva (Coluna CL_FHL - Número de Filhos)

A análise da variável numérica referente ao número de filhos dos clientes evidenciou parâmetros cruciais para a caracterização do perfil do consumidor:

Parâmetro Estatístico	Valor Calculado
Média	1,15
Mediana	0,00
Moda	0,00
Mínimo	0
Máximo	4




Diagnóstico da Distribuição: A presença de uma média de **1,15** em contraste com a mediana e moda em **0,00** confirma uma distribuição assimétrica positiva (à direita). A concentração de valores nulos (clientes sem filhos) ancora a mediana no zero, enquanto a cauda superior de 1 a 4 dependentes eleva a média aritmética.

4. Principais Insights e Descobertas de Negócio

4.1. Perfil e Composição Familiar

Qtd. de Filhos	Total de Clientes	Proporção Relativa
0 Filhos	384.986	52,5% (Moda)
1 Filho	90.845	12,4%
2 Filhos	94.168	12,8%
3 Filhos	92.407	12,6%


Qtd. de Filhos	Total de Clientes	Proporção Relativa
4 Filhos	71.041	9,7%



- **Volume Sem Filhos:** Mais da metade da base (384.986 clientes) declara não ter filhos cadastrados.
- **Homogeneidade entre 1 e 3 filhos:** Há estabilidade no volume de clientes que possuem 1, 2 ou 3 filhos (entre 90 mil e 94 mil em cada faixa), sofrendo leve recuo apenas na faixa de 4 filhos (71.041 clientes). O total acumulado de famílias com dependentes representa aproximadamente 348,4 mil clientes.

4.2. Distribuição por Gênero

Proporção de Clientes por Gênero



- **Feminino (F):** 52,1% do total de clientes.
- **Masculino (M):** 47,9% do total de clientes.
- **Equilíbrio Demográfico:** A distribuição quase paritária indica paridade de representatividade na base cadastral, sugerindo que campanhas institucionais e ações promocionais gerais devem manter uma abordagem equilibrada de sortimento.

5. Recomendações Estratégicas

1. Segmentação de Campanhas e CRM:

- *Público 0 Filhos:* Focar em produtos de consumo individual, conveniência, autocuidado e estilo de vida.
- *Público com Dependentes (1 a 4 filhos):* Direcionar comunicações voltadas a volta às aulas, produtos infantis, vestuário familiar e lazer doméstico.